



Università degli Studi di Salerno
Corso di Fondamenti di Visione Artificiale e Biometria
2025/2026

Stress-testing dell'explainability nei MLLM

Questo non è un *prompt*?

Tutor: Lucia Cascone lcascone@unisa.it



Obiettivo

- Investigare **metodi di explainability** per comprendere il comportamento dei modelli vision-language
- Analizzare come il modello costruisce la risposta attraverso **grounding visivo token per token**
- Valutare la **stabilità** delle spiegazioni al variare di prompt e contenuto visivo
- Esaminare la **coerenza semantica** delle attivazioni
- Impiegare queste strategie come strumenti di **analisi diagnostica** di errori, debolezze e dipendenze spurie



Introduzione al Problema

- I modelli Vision-Language generano output convincenti
- Ma il processo decisionale è **opaco**

Non sappiamo:

- **cosa** il modello guarda
- **quando** usa l'informazione visiva
- come genera ogni token

Output corretto $\neq$ ragionamento corretto

Approccio Metodologico



Studi proposti



Prompt Ablation

→ effetto del linguaggio sul grounding



Image Perturbation

→ robustezza al degrado visivo



Token-Level Analysis

→ qualità semantica delle attivazioni



Token Aggregation

→ coerenza tra token correlati



Layer Aggregation

→ evoluzione del grounding nei layer



Failure & Bias Analysis

→ identificazione di errori e dipendenze spurie



Stato dell'Arte

Codice (vi verrà fornita una versione leggermente modificata): <https://github.com/xmed-lab/TAM>

Paper:

https://openaccess.thecvf.com/content/ICCV2025/papers/Li_Token_Activation_Map_to_Visually_Explain_Multimodal_LLMs_ICCV_2025_paper.pdf

https://openaccess.thecvf.com/content/ICCV2025/supplemental/Li_Token_Activation_Map_ICCV_2025_supplemental.pdf



Materiale da produrre

- Archivio contenente il codice prodotto (.py o .ipynb) opportunamente commentato e corredato di tutti i files utili all'esecuzione
- Short-paper strutturato come di seguito:
 1. Abstract
 2. Introduzione e descrizione del problema
 3. Stato dell'arte/Related Works
 4. Sistema proposto (sezione in cui esporre la strategia implementativa adottata)
 5. Risultati sperimentali (sezione in cui vengono presentati i risultati raggiunti in termini di metriche come accuracy, F1-score, MSE etc..)
 6. Discussione dei risultati (sezione in cui discutere e analizzare i risultati ottenuti)
 7. Conclusioni
- Presentazione finale



Università degli Studi di Salerno

Corso di Fondamenti di Visione Artificiale e Biometria
2025/2026

Stress-testing dell'explainability nei MLLM

Questo non è un *prompt*?

Tutor: Lucia Cascone lcascone@unisa.it

